Лабораторная работа 0-1 по курсу "Машинное обучение"

Студент	Цыкин
Группа	301

Подключение библиотек

```
In [1]:
    import numpy as np
    import pandas as pd
    import matplotlib.pyplot as plt
    import seaborn as sns

In [2]:
    from scipy.stats import mode
    from sklearn.metrics import accuracy_score, confusion_matrix, recall_sco.
    import warnings
    warnings.filterwarnings('ignore')
    from sklearn.model_selection import GridSearchCV
    from sklearn.base import BaseEstimator, ClassifierMixin
    from sklearn.model_selection import train_test_split
    from sklearn.metrics import auc
    import joblib
```

В этой части я подключаю необходимые библиотеки для реализации работы

Загрузка данных

```
In [3]:
         df = pd.read_csv('Data_classified_phase_.csv')
         df.shape
        (15388, 28)
Out[3]:
In [4]:
         df.columns
        Index(['Kpmag', 'numax', 'e numax', 'Delnu', 'e Delnu', 'A', 'e A', 'Widt
Out[4]:
                'e Width', 'Teff', 'e Teff', '\log(g)', 'e\log(g)', '[Fe/H]', 'e_[F
        e/H]',
                'NoCorM', 'e_NoCorM', 'NoCorR', 'e_NoCorR', 'RGBcorM', 'e_RGBcor
        Μ',
                'RGBcorR', 'e RGBcorR', 'ClcorM', 'e ClcorM', 'ClcorR', 'e Clcor
        R',
                'Phase'],
              dtype='object')
```

Pipeline

```
In [5]: from sklearn.pipeline import Pipeline
```

Здесь я описал функцию, которая преобразает данные, как это было сделанно в 0

лабораторной работе. Но некоторые есть исключения, потерянные данные я поменял на среднее значения звезд первого класса, а так же нормировка данных.

```
In [6]:
         def trans(data):
             df = data.copy()
             arr = []
             for column in df.columns:
                 if df.dtypes[column] == 'object':
                     arr.append(column)
             for i in range (1, 20):
                 df[df == i*' '] = np.nan
             for i in arr:
                df[i] = pd.to numeric(df[i])
             df 1 = df[df['Phase'] == 1]
             for i in arr:
                 df[i] = df[i].fillna(df[i].mean())
             par = ["NoCorM", "e_NoCorM", "NoCorR", "e_NoCorR", "RGBcorM", "e_RGB
             df = df.drop(par, axis = 1)
             df=(df-df.mean())/df.std()
             return df
         class SpInpTransformer():
             def init (self,f):
                 self.func = f
             def transform(self, input_df, **transform_params):
                 return self.func(input df)
             def fit(self, X, y = None, **fit params):
                 return self
In [7]:
       X = df
In [8]:
         df_y = df.copy()
         y = df y['Phase']
In [9]:
        X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,
```

Линейная регрессия

```
In [10]:

#коробочный классификатор
from sklearn.linear_model import LinearRegression

In [11]:

#СВОЯ реализация
class my_LinearRegression(BaseEstimator, ClassifierMixin):
    def __init__(self, lr=0.01):
        self.lr = lr
        self.iters = 1500
        self.w = None
        self.b = None

def fit(self, X, y):
```

```
samples, features = X.shape
self.w = np.zeros(features)
self.b = 0

for i in range(self.iters):
    pred = np.dot(X, self.w) + self.b
    dw = 1/samples * np.dot(X.T, (pred - y))
    db = 1/samples * np.sum(pred - y)
    self.w -= self.lr * dw
    self.b -= self.lr * db

def predict(self, X):
    pred = np.dot(X, self.w) + self.b
    y_pred = np.where(pred <= 1.5, 1, 2)
    return y_pred

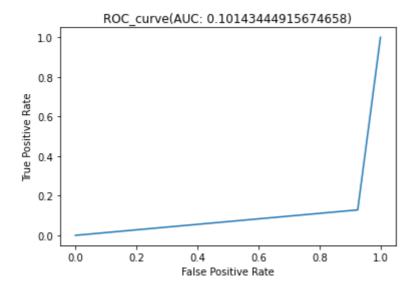
def get_params(self, deep=True):
    return self.lr</pre>
```

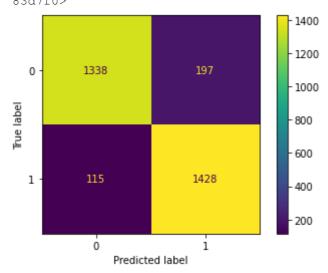
Составление Pipeline'ов для моего классификатора и коробочного классификатора линейной регрессии

Моя модель

```
In [13]:
          my_clf.fit(X_train, y_train)
          y_pred = my_clf.predict(X_test)
          print('Accuracy - ', accuracy_score(y_test, y_pred))
          print('recall_score - ', recall_score(y_test, y_pred))
          print('precision - ', precision_score(y_test, y_pred))
          fpr, tpr, thresholds = roc curve(y test, y pred, pos label=1)
          AUC = auc(fpr, tpr)
          plt.plot(fpr, tpr)
          plt.title('ROC curve' + '(AUC: ' + str(AUC) + ')')
          plt.ylabel('True Positive Rate')
          plt.xlabel('False Positive Rate')
          plt.show()
          print('confusion matrix:')
          matrix = confusion matrix(y test, y pred)
          plot = ConfusionMatrixDisplay(confusion matrix=matrix)
          plot.plot()
```

Accuracy - 0.898635477582846 recall_score - 0.8716612377850163 precision - 0.9208534067446662

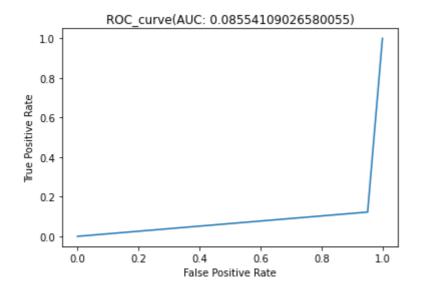




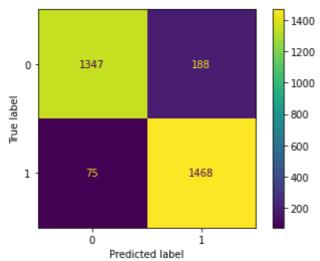
Коробочная модель линейной регрессии

```
In [14]:
          clf.fit(X_train, y_train)
          y_pred = clf.predict(X_test)
          y_pred = np.where(y_pred \leftarrow 1.5, 1, 2)
          print('Accuracy - ', accuracy_score(y_test, y_pred.astype(int)))
          print('recall_score - ', recall_score(y_test, y_pred.astype(int)))
          print('precision - ', precision_score(y_test, y_pred.astype(int)))
          fpr, tpr, thresholds = roc_curve(y_test, y_pred.astype(int), pos_label=1
          AUC = auc(fpr, tpr)
          plt.plot(fpr, tpr)
          plt.title('ROC_curve' + '(AUC: ' + str(AUC) + ')')
          plt.ylabel('True Positive Rate')
          plt.xlabel('False Positive Rate')
          plt.show()
          print('confusion matrix:')
          matrix = confusion_matrix(y_test, y_pred.astype(int))
          plot = ConfusionMatrixDisplay(confusion matrix=matrix)
          plot.plot()
```

Accuracy - 0.9145549057829759 recall_score - 0.8775244299674267 precision - 0.9472573839662447



confusion matrix:
Out[14]:
confusion matrix.
confusionMatrixDisplay at 0x27c75
9cd5b0>



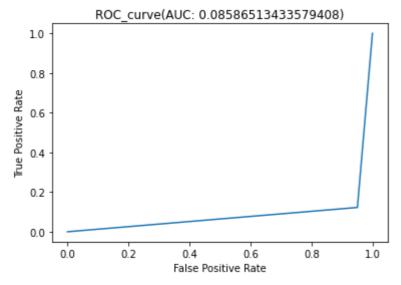
Как можно отметить, результат коробочного классификатора лучше моего. Дальше попробуем определить наилушие параметры для классификатора. Не разобрался с использованием GridsearchCV для линейной регрессии, поэтому реализовал сам.

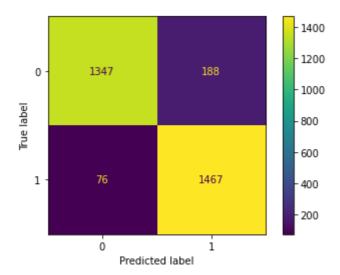
Построим наилучший классификатор и создадим файл pickle

```
In [17]:
          my clf.fit(X train, y train)
          y pred = my clf.predict(X test)
          print('Accuracy - ', accuracy_score(y_test, y_pred))
          print('recall_score - ', recall_score(y_test, y_pred))
          print('precision - ', precision_score(y_test, y_pred))
          fpr, tpr, thresholds = roc curve(y test, y pred, pos label=1)
          AUC = auc(fpr, tpr)
          plt.plot(fpr, tpr)
          plt.title('ROC curve' + '(AUC: ' + str(AUC) + ')')
          plt.ylabel('True Positive Rate')
          plt.xlabel('False Positive Rate')
          plt.show()
          print('confusion matrix:')
          matrix = confusion_matrix(y_test, y_pred)
          plot = ConfusionMatrixDisplay(confusion matrix=matrix)
          plot.plot()
```

Accuracy - 0.9142300194931774 recall_score - 0.8775244299674267 precision - 0.9465917076598735

Out[17]:





Как можем отметить, при использовании lr = 0.3 удалось построить наилучший классификатор и добиться улучшения точности на 2 процента.

```
In [18]: joblib.dump(my_clf, "lin_reg.pkl")
Out[18]: ['lin_reg.pkl']
In [19]: clf = joblib.load("lin_reg.pkl")
    y_pred = clf.predict(X_test)
    accuracy_score(y_pred, y_test)
Out[19]: 0.9142300194931774
```

Naive Bayes

```
In [20]:
          from sklearn.naive bayes import GaussianNB
In [21]:
          class NaiveBayes(BaseEstimator, ClassifierMixin):
              def __init__(self):
                  self.classes = None
                  self.n = 0
                  self.mean = None
                  self.var = None
                  self.pri = None
              def fit(self, X, y):
                  samples, features = X.shape
                  self.classes = np.unique(y)
                  self.n = len(self.classes)
                  self.mean = np.zeros((self.n, features), dtype=np.float64)
                  self.var = np.zeros((self.n, features), dtype=np.float64)
                  self.pri = np.zeros(self.n, dtype=np.float64)
                  for j in self.classes:
                      X = X[j==y]
                      self.mean[j-1] = X .mean(axis=0)
                      self.var[j-1] = X_.var(axis=0)
                      self.pri[j-1] = X .shape[0]/float(self.n)
```

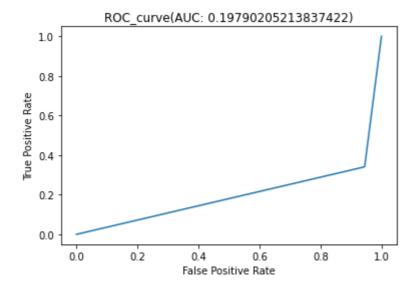
```
def func(self, idx, x):
   mean = self.mean[idx]
   var = self.var[idx]
    num = np.exp(- (x-mean)**2 / (2*var))
    denum = np.sqrt(2 * np.pi * var)
    k = num / denum
    return k
def predict(self, x):
    post = []
    for k in range(len(self.classes)):
        pri = np.log(self.pri[k])
        class cond = np.sum(np.log(self.func(k, x)))
        poster = pri + class cond
        post.append(poster)
    return self.classes[np.argmax(post)]
def predict(self, X):
    pred = [self._predict(x) for x in X.to_numpy()]
    return pred
```

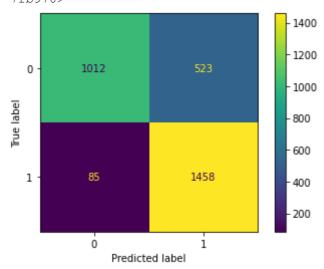
Составление Pipeline'ов для моего классификатора и коробочного классификатора Баевского метода

Моя модель

precision - 0.9225159525979946

```
In [23]:
         my_clf.fit(X_train, y_train)
          y_pred = my_clf.predict(X_test)
          print('Accuracy - ', accuracy score(y test, y pred))
          print('recall_score - ', recall_score(y_test, y_pred))
          print('precision - ', precision_score(y_test, y_pred))
          fpr, tpr, thresholds = roc curve(y test, y pred, pos label=1)
          AUC = auc(fpr, tpr)
          plt.plot(fpr, tpr)
          plt.title('ROC curve' + '(AUC: ' + str(AUC) + ')')
          plt.ylabel('True Positive Rate')
          plt.xlabel('False Positive Rate')
          plt.show()
          print('confusion matrix:')
          matrix = confusion matrix(y test, y pred)
          plot = ConfusionMatrixDisplay(confusion matrix=matrix)
          plot.plot()
         Accuracy - 0.8024691358024691
         recall score - 0.6592833876221499
```

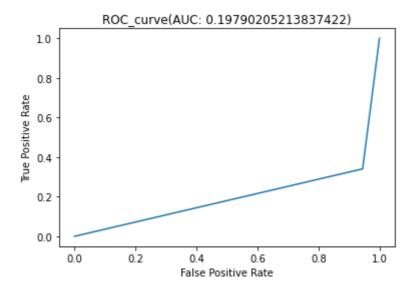




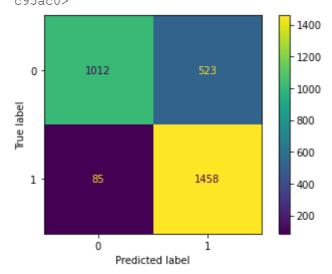
Коробочная модель Баевского метода

```
In [24]:
          clf.fit(X_train, y_train)
          y_pred = clf.predict(X_test)
          print('Accuracy - ', accuracy_score(y_test, y_pred))
          print('recall_score - ', recall_score(y_test, y_pred))
          print('precision - ', precision_score(y_test, y_pred))
          fpr, tpr, thresholds = roc_curve(y_test, y_pred, pos_label=1)
          AUC = auc(fpr, tpr)
          plt.plot(fpr, tpr)
          plt.title('ROC_curve' + '(AUC: ' + str(AUC) + ')')
          plt.ylabel('True Positive Rate')
          plt.xlabel('False Positive Rate')
          plt.show()
          print('confusion matrix:')
          matrix = confusion_matrix(y_test, y_pred)
          plot = ConfusionMatrixDisplay(confusion matrix=matrix)
          plot.plot()
```

Accuracy - 0.8024691358024691 recall_score - 0.6592833876221499 precision - 0.9225159525979946



confusion matrix:
Out[24]:
confusion matrix.
confusionMatrixDisplay at 0x27c75
c95ac0>



GridSeearchCV для поиска наилучших параметров

```
In [25]:
          parameters = {
              'model__var_smoothing': np.logspace(0,-9, num=100)
          grid searcher = GridSearchCV(clf,
                                      param grid = parameters,
                                      cv = 5)
          grid searcher.fit(X train, y train)
         GridSearchCV(cv=5,
Out[25]:
                      estimator=Pipeline(steps=[('trans',
                                                  < main .SpInpTransformer object</pre>
         at 0x0000027C7587E220>),
                                                  ('model', GaussianNB())]),
                      param_grid={'model__var_smoothing': array([1.0000000e+00,
         8.11130831e-01, 6.57933225e-01, 5.33669923e-01,
                4.32876128e-01, 3.51119173e-01, 2.84803587e-01, 2.31012970e-01,
                1.87381742e-01, 1.51991108e-01, 1.23284674e-01, 1.00000000...
                1.23284674e-07, 1.00000000e-07, 8.11130831e-08, 6.57933225e-08,
                5.33669923e-08, 4.32876128e-08, 3.51119173e-08, 2.84803587e-08,
                2.31012970e-08, 1.87381742e-08, 1.51991108e-08, 1.23284674e-08,
                1.00000000e-08, 8.11130831e-09, 6.57933225e-09, 5.33669923e-09,
```

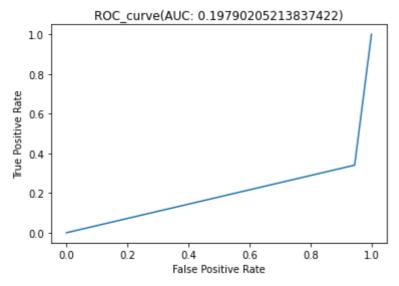
```
4.32876128e-09, 3.51119173e-09, 2.84803587e-09, 2.31012970e-09, 1.87381742e-09, 1.51991108e-09, 1.23284674e-09, 1.00000000e-09])})
```

```
In [26]: grid_searcher.best_params_
```

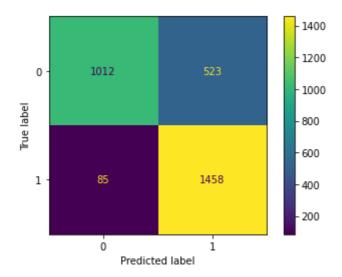
Out[26]: {'model__var_smoothing': 8.111308307896872e-05}

```
In [27]:
          y pred = grid searcher.predict(X test)
          print('Accuracy - ', accuracy_score(y_test, y_pred))
          print('recall_score - ', recall_score(y_test, y_pred))
          print('precision - ', precision score(y test, y pred))
          fpr, tpr, thresholds = roc curve(y test, y pred, pos label=1)
          AUC = auc(fpr, tpr)
          plt.plot(fpr, tpr)
          plt.title('ROC_curve' + '(AUC: ' + str(AUC) + ')')
          plt.ylabel('True Positive Rate')
          plt.xlabel('False Positive Rate')
          plt.show()
          print('confusion matrix:')
          matrix = confusion matrix(y test, y pred)
          plot = ConfusionMatrixDisplay(confusion matrix=matrix)
          plot.plot()
```

Accuracy - 0.8024691358024691 recall_score - 0.6592833876221499 precision - 0.9225159525979946



confusion matrix:



Как можно заметить, точнось не улучшилась поэтому сохраню свой классификатор в формате pickle

SVM

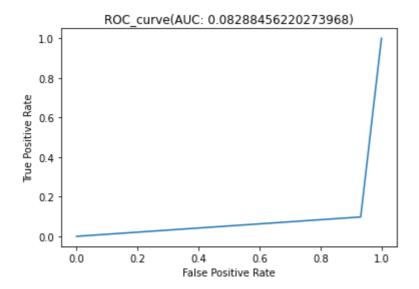
```
In [30]:
          from sklearn.svm import SVC
In [31]:
          class SVM(BaseEstimator, ClassifierMixin):
              def __init__(self, lr=0.01, lamb=0.01, iters=1000):
                   self.lr = lr
                  self.lamb = lamb
                  self.iters = iters
                  self.w = None
                  self.b = None
                  self.n = 0
                   self.m = 0
              def fit(self, X, y):
                  self.n = y.max()
                  self.m = y.min()
                  y_{-} = np.where(y \le (self.n+self.m)/2, -1, 1)
                  samples, features = X.shape
                  self.w = np.zeros(features)
                   self.b = 0
                  for i in range(self.iters):
                       for j, x_j in enumerate(X.to_numpy()):
                           cond = y_{[j]} * (np.dot(x_j, self.w) - self.b) >= 1
                           if cond:
```

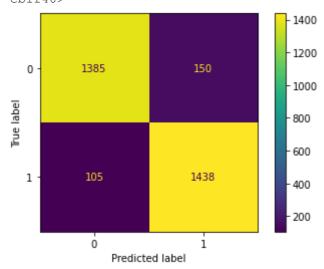
Составление Pipeline'ов для моего классификатора и коробочного классификатора SVM

Моя модель

```
In [33]:
          my clf.fit(X train, y train)
          y pred = my clf.predict(X test)
          print('Accuracy - ', accuracy_score(y_test, y_pred))
          print('recall_score - ', recall_score(y_test, y_pred))
          print('precision - ', precision score(y test, y pred))
          fpr, tpr, thresholds = roc_curve(y_test, y_pred, pos_label=1)
          AUC = auc(fpr, tpr)
          plt.plot(fpr, tpr)
          plt.title('ROC_curve' + '(AUC: ' + str(AUC) + ')' )
          plt.ylabel('True Positive Rate')
          plt.xlabel('False Positive Rate')
          plt.show()
          print('confusion matrix:')
          matrix = confusion matrix(y test, y pred)
          plot = ConfusionMatrixDisplay(confusion matrix=matrix)
          plot.plot()
```

Accuracy - 0.9171539961013645 recall_score - 0.9022801302931596 precision - 0.9295302013422819

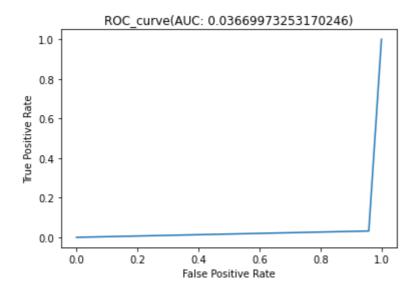


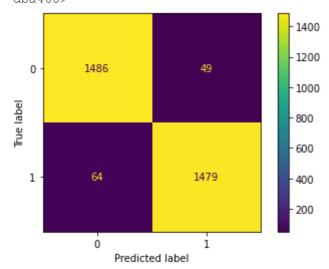


Коробочная модель SVM(SVC)

```
In [34]:
          clf.fit(X_train, y_train)
          y_pred = clf.predict(X_test)
          print('Accuracy - ', accuracy_score(y_test, y_pred))
          print('recall_score - ', recall_score(y_test, y_pred))
          print('precision - ', precision_score(y_test, y_pred))
          fpr, tpr, thresholds = roc_curve(y_test, y_pred, pos_label=1)
          AUC = auc(fpr, tpr)
          plt.plot(fpr, tpr)
          plt.title('ROC_curve' + '(AUC: ' + str(AUC) + ')')
          plt.ylabel('True Positive Rate')
          plt.xlabel('False Positive Rate')
          plt.show()
          print('confusion matrix:')
          matrix = confusion_matrix(y_test, y_pred)
          plot = ConfusionMatrixDisplay(confusion matrix=matrix)
          plot.plot()
```

Accuracy - 0.9632878492527616 recall_score - 0.9680781758957655 precision - 0.9587096774193549



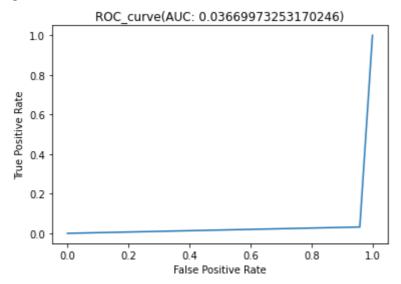


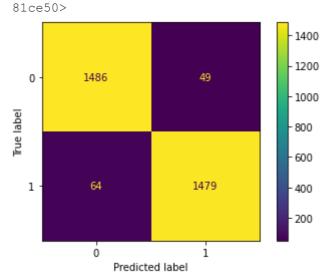
GridSearchCV для SVM

```
In [35]:
           param_grid = {'model__C':[0.1, 1, 10, 100],}
           grid_searcher = GridSearchCV(clf, param_grid, cv = 5)
           grid_searcher.fit(X_train, y_train)
          GridSearchCV(cv=5,
Out[35]:
                        estimator=Pipeline(steps=[('trans',
                                                       <__main__.SpInpTransformer object
          at 0x0000027C75AE4BB0>),
                                                      ('model', SVC())]),
                        param grid={'model C': [0.1, 1, 10, 100]})
In [36]:
           grid_searcher.best_params_
          {'model C': 1}
Out[36]:
In [37]:
           y pred = grid searcher.predict(X test)
           print('Accuracy - ', accuracy_score(y_test, y_pred))
           print('recall_score - ', recall_score(y_test, y_pred))
print('precision - ', precision_score(y_test, y_pred))
           fpr, tpr, thresholds = roc curve(y test, y pred, pos label=1)
           AUC = auc(fpr, tpr)
```

```
plt.plot(fpr, tpr)
plt.title('ROC_curve' + '(AUC: ' + str(AUC) + ')' )
plt.ylabel('True Positive Rate')
plt.xlabel('False Positive Rate')
plt.show()
print('confusion matrix:')
matrix = confusion_matrix(y_test, y_pred)
plot = ConfusionMatrixDisplay(confusion_matrix=matrix)
plot.plot()
```

Accuracy - 0.9632878492527616 recall_score - 0.9680781758957655 precision - 0.9587096774193549





Out[37]:

Наилучшим оказался коробочный классификатор, сохраним его

KNN

```
In [40]:
          from sklearn.neighbors import KNeighborsClassifier
In [41]:
          class KNN(BaseEstimator, ClassifierMixin):
              def init (self, n val=5):
                  self.n val = n val
                  self.train = None
                  self.validation = None
              def fit(self, X, y):
                  self.train = X
                  self.validation = y
              def predict(self, X):
                  prediction = []
                  j = 1
                  n = len(X)
                  for y test in X.to numpy():
                      distance = []
                      for i in range(len(self.train)):
                          distance.append(np.linalg.norm(np.array(self.train.iloc[
                      distance data = pd.DataFrame(data = distance, columns = ['di
                      neighbours = distance data.sort values(by='dist', axis=0)[:s
                      labels = self.validation.loc[neighbours.index]
                      vote = mode(labels).mode[0]
                      prediction.append(vote)
                      j+=1
                  return prediction
```

Составление Pipeline'ов для моего классификатора и коробочного классификатора KNN

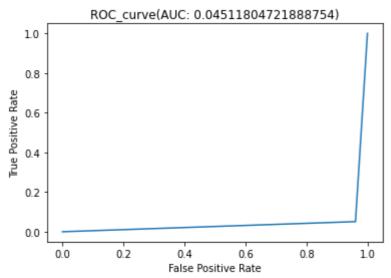
Моя модель

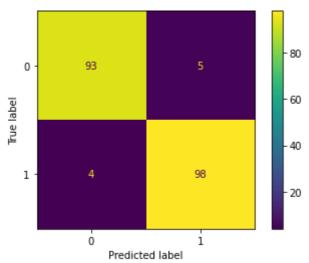
Использовал на малом числе тестовых значений, потому что работал долго

```
In [43]:
    my_clf.fit(X_train, y_train)
    y_pred = my_clf.predict(X_test[:200])
    print('Accuracy - ', accuracy_score(y_test[:200], y_pred))
```

```
print('recall_score - ', recall_score(y_test[:200], y_pred))
print('precision - ', precision_score(y_test[:200], y_pred))
fpr, tpr, thresholds = roc_curve(y_test[:200], y_pred, pos_label=1)
AUC = auc(fpr, tpr)
plt.plot(fpr, tpr)
plt.plot(fpr, tpr)
plt.vlabel('ROC_curve' + '(AUC: ' + str(AUC) + ')')
plt.ylabel('True Positive Rate')
plt.xlabel('False Positive Rate')
plt.show()
print('confusion matrix:')
matrix = confusion_matrix(y_test[:200], y_pred)
plot = ConfusionMatrixDisplay(confusion_matrix=matrix)
plot.plot()
```

Accuracy - 0.955 recall_score - 0.9489795918367347 precision - 0.9587628865979382



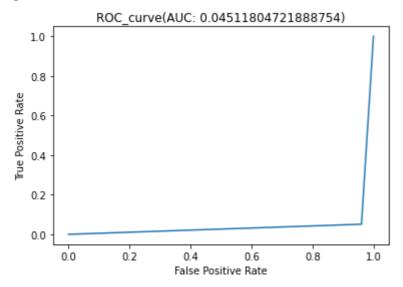


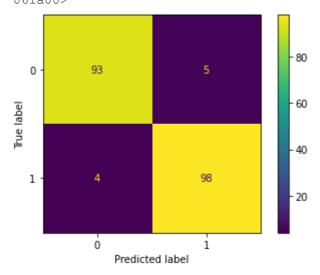
Коробочная модель KNN

```
In [44]:
    clf.fit(X_train, y_train)
    y_pred = clf.predict(X_test[:200])
    print('Accuracy - ', accuracy_score(y_test[:200], y_pred))
    print('recall_score - ', recall_score(y_test[:200], y_pred))
    print('precision - ', precision_score(y_test[:200], y_pred))
```

```
fpr, tpr, thresholds = roc_curve(y_test[:200], y_pred, pos_label=1)
AUC = auc(fpr, tpr)
plt.plot(fpr, tpr)
plt.title('ROC_curve' + '(AUC: ' + str(AUC) + ')')
plt.ylabel('True Positive Rate')
plt.xlabel('False Positive Rate')
plt.show()
print('confusion matrix:')
matrix = confusion_matrix(y_test[:200], y_pred)
plot = ConfusionMatrixDisplay(confusion_matrix=matrix)
plot.plot()
```

```
Accuracy - 0.955
recall_score - 0.9489795918367347
precision - 0.9587628865979382
```

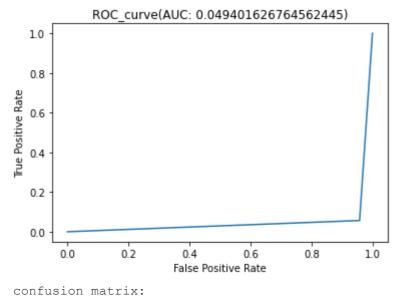


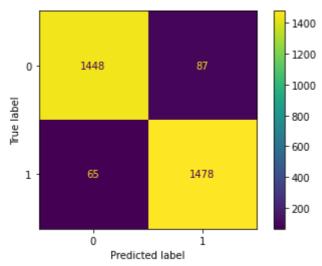


GridSearchCV для KNN

```
grid searcher.best params
         {'knn n neighbors': 7}
Out[46]:
In [47]:
          y pred = grid searcher.predict(X test)
          print('Accuracy - ', accuracy score(y test, y pred))
          print('recall_score - ', recall_score(y_test, y_pred))
          print('precision - ', precision_score(y_test, y_pred))
          fpr, tpr, thresholds = roc curve(y test, y pred, pos label=1)
          AUC = auc(fpr, tpr)
          plt.plot(fpr, tpr)
          plt.title('ROC curve' + '(AUC: ' + str(AUC) + ')')
          plt.ylabel('True Positive Rate')
          plt.xlabel('False Positive Rate')
          plt.show()
          print('confusion matrix:')
          matrix = confusion_matrix(y_test, y_pred)
          plot = ConfusionMatrixDisplay(confusion_matrix=matrix)
          plot.plot()
         Accuracy - 0.9506172839506173
```

Accuracy - 0.9506172839506173 recall_score - 0.9433224755700326 precision - 0.9570389953734303





На испытании на тестовых данных с 7 ближайшими соседями выдал тоже хороший

результат, сохраним его

```
In [48]: joblib.dump(grid_searcher, "KNN.pkl")
Out[48]: ['KNN.pkl']
In [49]: clf = joblib.load("KNN.pkl")
    y_pred = clf.predict(X_test)
    accuracy_score(y_pred, y_test)
Out[49]: 0.9506172839506173
```

Вывод лабораторной работы 1

В данной части лабораторной работы мной были изучены и составлены 4 предложенных классификатора. С помощью их удалось добиться хороших результатов. Все результаты больше 80. Также был изучен pipeline, который позволяет создавать последовательные стадии использования классификатора (pre-processing, classification ...). Во время выполнения работы также использовал метод GridSearchCV, для определения лучших параметров и использовании кросс-валидации. В результате чего, удалось добиться еще более лучших результатов даже 95 %. Наилушие классификаторы были сохранены в файл формата pickle.